

COMPTE RENDU TECHNIQUE

TP 1 — Systèmes de recommandation

TP 2 — Filtrage collaboratif

Formation : Master Sciences des Données

Année : 2025–2026

Jeux de données : MovieLens Latest Small et MovieLens 100K

Environnement : Python 3.12 • NumPy 2.3.5 • pandas 2.2.3 • scikit-learn 1.8

Date du rendu : 1er septembre 2026

Résumé exécutif

Résultat principal

Le centrage des notes est le levier le plus déterminant. Sur le TP 1, la SVD centrée de rang 5 obtient la meilleure RMSE (0,9162). Sur le TP 2, le filtrage item-based centré avec $k = 200$ atteint la meilleure MSE de test (0,9416).

Les deux sujets ont été implémentés dans deux notebooks Colab autonomes. Les données sont téléchargées à l'exécution depuis la source officielle Grouplens ; elles ne sont pas incluses dans les livrables. Les expériences utilisent une graine fixe (42), des divisions apprentissage/test sans fuite et des tests unitaires sur les opérations sensibles.

- TP 1 : 100 836 notes, 610 utilisateurs, 9 724 films ; séparation globale 80/20.
- TP 2 : 100 000 notes, 943 utilisateurs, 1 682 films ; 10 notes de test par utilisateur.
- Évaluation : RMSE/MSE pour la précision des notes et NDCG@10 pour la qualité du classement.

1. Cadre expérimental

1.1 Objectifs couverts

Le TP 1 demande de construire une chaîne complète allant de la matrice d'utilité au filtrage collaboratif user-based et item-based, puis à la factorisation SVD. Le TP 2 approfondit la même famille de méthodes : split par utilisateur, similarité cosinus, prédictions pondérées, influence de k, débiaisage et recherche de films voisins selon cosinus et Pearson.

- construire les matrices utilisateur-film sans confondre une note nulle avec une valeur manquante ;
- calculer les similarités et exclure l'entité elle-même des voisinages ;
- prédire uniquement à partir des notes disponibles dans l'apprentissage ;
- comparer les modèles sur des observations jamais utilisées pour l'ajustement ;
- interpréter les écarts entre erreur de note et qualité de classement.

1.2 Reproductibilité et contrôle de qualité

Contrôle	Mise en œuvre	Résultat
Données	GroupLens puis miroir automatique en secours	Téléchargement robuste dans Colab
Aléatoire	Graine SEED = 42	Splits reproductibles
Valeurs manquantes	Zéros exclus des moyennes	Biais non dilué par la sparsité
Fuite de données	Masques train/test disjoints	Aucune observation partagée
Tests	5 tests unitaires + intégration	5/5 réussis
Notebooks	Exécution complète avec sorties embarquées	Aucune cellule en erreur

Source : calculs reproductibles des notebooks fournis.

Les fonctions communes sont regroupées dans `recommender_core.py` et également embarquées dans chaque notebook afin qu'un fichier .ipynb puisse être ouvert et exécuté seul dans Google Colab.

1.3 Mesures

La RMSE pénalise davantage les grandes erreurs et reste exprimée dans l'unité de la note. La MSE est son carré. NDCG@10 compare l'ordre des dix recommandations au classement idéal et mesure donc une propriété différente de la calibration numérique.

$$RMSE = \sqrt{\frac{1}{|T|} \cdot \sum_{(u,i) \in T} (r_{ui} - \hat{r}_{ui})^2}$$

$$NDCG@10 = DCG@10 / IDC@10$$

2. TP 1 — Systèmes de recommandation

2.1 Données et matrice d'utilité (questions 1.a-1.b)

MovieLens Latest Small fournit 100 836 évaluations explicites. Après le split global 80/20, la matrice d'apprentissage a une densité de seulement 1,360 %, ce qui confirme que l'essentiel de la matrice est inconnu. Les identifiants d'utilisateurs et de films sont convertis en indices contigus, tout en conservant les mappings inverses pour restituer les titres.

Indicateur	Valeur	Lecture
Évaluations	100 836	Toutes les notes disponibles
Utilisateurs	610	Lignes de la matrice
Films	9 724	Colonnes de la matrice
Densité train	1.360 %	Matrice très creuse

Source : calculs reproductibles des notebooks fournis.

2.2 Similarité et prédiction (questions 1.c-1.f)

Les produits scalaires utilisateur-utilisateur et film-film sont calculés par multiplication matricielle. Les normes pré-calculées transforment ensuite ces produits en cosinus sans recalculer les vecteurs. Pour une paire cible, les voisins sont triés, l'auto-similarité est exclue et seuls les voisins ayant une note observée contribuent à la prédiction.

$$\text{sim}(a,b) = (a \cdot b) / (\|a\|_2 \cdot \|b\|_2)$$

$$\hat{r}_{ui} = \sum_v \text{sim}(u,v) \cdot r_{vi} / \sum_v |\text{sim}(u,v)|$$

Cas sans voisin exploitable

Lorsque le dénominateur est nul, la prédiction se replie sur la moyenne globale. Les scores sont ensuite bornés dans l'intervalle valide [0,5 ; 5].

2.3 Résultats du filtrage collaboratif (questions 1.g-1.j)

Modèle	RMSE	NDCG@10
User-based brut, k=10	1.0610	0.0233
Item-based brut, k=10	0.9974	0.0275
User-based centré, k=10	0.9563	0.0237
Item-based centré, k=10	0.9435	0.0259

Source : calculs reproductibles des notebooks fournis.

Le centrage réduit la RMSE user-based de 0,1046 et la RMSE item-based de 0,0539. La variante item-based centrée est la meilleure des quatre (0,9435). Les NDCG@10 des méthodes locales restent faibles : avec un split global et une matrice très creuse, une grande partie des items de test ne reçoit que peu de signal de voisinage.

2.4 Factorisation SVD (questions 1.k–1.m)

La matrice d'apprentissage est décomposée par SVD puis reconstruite à différents rangs N . Deux variantes sont évaluées : la matrice brute où les zéros sont factorisés tels quels, et la matrice centrée par la moyenne de chaque utilisateur, où seuls les résidus observés sont conservés.

$$R \approx U_n \cdot \text{diag}(\sigma_1, \dots, \sigma_n) \cdot V_n^T$$

Variante	Rang optimal	RMSE	NDCG@10
SVD brute	10	2.7874	0.2433
SVD centrée	5	0.9162	0.1316

Source : calculs reproductibles des notebooks fournis.




Figure 1 — Influence du rang et distribution des scores : SVD brute contre SVD centrée.

Le meilleur rang brut est 10, tandis que le meilleur rang après centrage est 5. Au-delà, la RMSE augmente progressivement : les composantes supplémentaires commencent à reconstruire du bruit et les zéros structurels. La SVD centrée obtient la meilleure RMSE de tout le TP (0,9162).

2.5 Distribution des scores et analyse (questions 1.n–1.o)




Figure 2 — Distribution des scores SVD brute sur les observations de test.

La SVD brute traite les zéros de la matrice comme de faibles notes. Elle produit donc des estimations fortement comprimées vers le bas, souvent hors de l'échelle utile : la calibration est mauvaise et la RMSE atteint 2,7874. Malgré cela, son NDCG@10 (0,2433) est le meilleur des modèles testés. Cette différence n'est pas contradictoire : les facteurs latents peuvent encore ordonner des films populaires de façon pertinente tout en prédisant de mauvaises valeurs absolues.

Interprétation des métriques

La RMSE mesure « combien » la note est fautive ; NDCG mesure « dans quel ordre » les films sont proposés. Une méthode peut donc être mal calibrée mais relativement efficace pour classer.

2.6 Réponse synthétique au TP 1

1. Le cosinus permet un calcul cohérent pour les deux orientations user-based et item-based.
2. À $k=10$, l'item-based centré domine les variantes de filtrage collaboratif en RMSE.
3. La SVD brute doit être évitée pour la prédiction de notes sur une matrice où zéro signifie « absent ».
4. Le centrage par utilisateur corrige le biais d'échelle et donne la meilleure RMSE globale avec une SVD de rang 5.
5. Le choix du modèle final dépend de l'objectif : précision numérique ou classement des recommandations.

3. TP 2 — Filtrage collaboratif

3.1 Données, sparsité et split par utilisateur

MovieLens 100K contient exactement 100 000 évaluations, fournies par 943 utilisateurs sur 1 682 films. La matrice a une densité de 6,3047 %, soit une sparsité stricte de 93,6953 %. Pour chaque utilisateur, dix notes sont déplacées vers le jeu de test. Ce protocole garantit une évaluation personnalisée pour tous les utilisateurs suffisamment actifs.

Indicateur	Valeur	Conséquence
Évaluations	100 000	Signal explicite
Utilisateurs	943	943 profils évalués
Films	1 682	Catalogue modéré
Densité	6.3047 %	Voisinages partiels
Sparsité	93.6953 %	Les valeurs manquantes dominant

Source : calculs reproductibles des notebooks fournis.

3.2 Similarités et premier voisin

Les similarités cosinus sont calculées sur la matrice d'apprentissage. Le plus proche voisin de l'utilisateur 1 est l'utilisateur 916, avec un cosinus de 0.5492. L'auto-similarité est explicitement neutralisée avant le tri.

3.3 Prédictions simples

Modèle	MSE test	RMSE test
User-based simple	7.9701	2.8231
Item-based simple	10.0612	3.1719

Source : calculs reproductibles des notebooks fournis.

Ces premières versions agrègent tous les voisins sans centrage. Elles servent de référence, mais restent sensibles aux différences de sévérité entre utilisateurs et aux niveaux moyens des films.

3.4 Influence du nombre de voisins k

k	MSE user-based	MSE item-based
5	3.1616	3.1180
15	1.7942	1.8117
30	1.3863	1.4388
50	1.2288	1.2473
100	1.1240	1.0986
200	1.0805	1.0615

Source : calculs reproductibles des notebooks fournis.




Figure 3 — Influence de k sur l'erreur d'apprentissage et de test des modèles bruts.

L'erreur test décroît nettement entre $k=5$ et $k=50$ puis s'aplatit. Dans la plage étudiée, le meilleur modèle brut est item-based avec $k=200$ (MSE 1,0615). La courbe ne présente pas de remontée avant 200 : les voisinages larges stabilisent ici les estimations et compensent la sparsité.

3.5 Débiaisage : centrage + top-k

Le modèle user-based soustrait à chaque utilisateur sa moyenne observée, puis la réinjecte après l'agrégation. La version item-based applique le même principe avec la moyenne observée de chaque film. Les zéros restent des valeurs manquantes et ne participent jamais au calcul des moyennes.

k	MSE user centré	MSE item centré
5	1.2249	1.1379
15	1.1515	1.1099
30	1.0652	1.0667
50	1.0075	1.0310
100	0.9699	0.9897
200	0.9481	0.9416

Source : calculs reproductibles des notebooks fournis.




Figure 4 — Erreur test : modèles bruts et modèles centrés selon k.

Le débiaisage améliore systématiquement les résultats. À $k=200$, la MSE item-based passe de 1,0615 à 0,9416, soit une baisse relative de 11,3 %. La variante user-based centrée atteint 0,9481, très proche du meilleur score.

3.6 Films similaires : cosinus et Pearson

Le cosinus mesure la proximité des profils de notes, mais reste influencé par le niveau moyen et la popularité. Pearson centre implicitement les profils sur les utilisateurs communs ; il met davantage en avant les écarts concordants. Les deux mesures produisent donc des listes voisines, sans être identiques.

Film cible	6 voisins — cosinus	6 voisins — Pearson
Toy Story	Star Wars (1977) Return of the Jedi (1983) Independence Day (ID4) (1996) Mission: Impossible (1996) Raiders of the Lost Ark (1981) Rock, The (1996)	Aladdin (1992) Mission: Impossible (1996) Star Wars (1977) Independence Day (ID4) (1996) Beauty and the Beast (1991) Willy Wonka and the Chocolate Factory (1971)
GoldenEye	Under Siege (1992) True Lies (1994) Top Gun (1986) Batman (1989) Die Hard: With a Vengeance (1995) Cliffhanger (1993)	Under Siege (1992) True Lies (1994) Cliffhanger (1993) Top Gun (1986) Die Hard: With a Vengeance (1995) Stargate (1994)
Muppet Treasure Island	Naked Gun 33 1/3: The Final Insult (1994) Aladdin (1992) Sgt. Bilko (1996) Hot Shots! Part Deux (1993) Sound of Music, The (1965) Stargate (1994)	Naked Gun 33 1/3: The Final Insult (1994) Sgt. Bilko (1996) Hot Shots! Part Deux (1993) Robin Hood: Men in Tights (1993) Lightning Jack (1994) Addams Family Values (1993)

Source : calculs reproductibles des notebooks fournis.

Pour GoldenEye, les deux métriques s'accordent fortement sur Under Siege, True Lies, Cliffhanger, Top Gun et Die Hard: With a Vengeance. Pour Toy Story et Muppet Treasure Island, Pearson introduit davantage de films proches par tonalité ou public, tandis que le cosinus conserve un signal de co-popularité.

Précaution d'interprétation

Une forte similarité ne signifie pas causalité ni équivalence éditoriale. Un seuil minimal de co-évaluations serait souhaitable avant une mise en production.

4. Synthèse comparative

Sujet	Modèle	Mesure	Score	Lecture
TP 1	SVD centrée, rang 5	RMSE	0.9162	Meilleure calibration
TP 1	SVD brute, rang 10	NDCG@10	0.2433	Meilleur classement
TP 2	Item-based brut, k=200	MSE	1.0615	Meilleur sans centrage
TP 2	Item-based centré, k=200	MSE	0.9416	Meilleur global TP 2

Source : calculs reproductibles des notebooks fournis.

4.1 Enseignements

- Le traitement correct des valeurs manquantes est aussi important que l'algorithme choisi.
- Le centrage corrige les biais de notation et améliore fortement la précision sur les deux jeux.
- Le paramètre k arbitre variance et stabilité ; sur MovieLens 100K, les voisinages larges restent bénéfiques jusqu'à 200.
- La SVD est efficace après correction de la moyenne, mais la SVD brute confond absence de note et préférence faible.
- RMSE/MSE et NDCG répondent à des objectifs distincts et doivent être examinées conjointement.

4.2 Limites

Limite	Effet possible	Amélioration proposée
Un seul split	Variance du score	Validation croisée ou plusieurs graines
Cosinus non régularisé	Voisins fragiles	Shrinkage selon le nombre de co-notes
Pas de biais global explicite	Calibration imparfaite	Modèle $\mu + b_u + b_i + \text{résidu}$
Pas de variables de contenu	Cold start	Hybridation genres/tags
Pas de contrainte métier	Top-N peu diversifié	Diversité, nouveauté et couverture

Source : calculs reproductibles des notebooks fournis.

4.3 Choix recommandé

Pour la prédiction de notes

Retenir la SVD centrée de rang 5 sur Latest Small et l'item-based centré avec k=200 sur MovieLens 100K, puis confirmer le choix sur plusieurs splits.

5. Conclusion

Les deux TP ont été réalisés intégralement, de l'ingestion des données à l'interprétation des résultats. Les implémentations montrent que les méthodes de voisinage restent compétitives lorsqu'elles sont correctement centrées et dotées d'un k suffisant. La factorisation SVD apporte la meilleure précision de note sur TP 1, mais uniquement après correction du biais utilisateur.

Les notebooks livrés sont autonomes, commentés, exécutables dans Google Colab et accompagnés de sorties déjà calculées. Le module Python commun, les métriques JSON et les tests unitaires permettent de reprendre les expériences dans un dépôt GitHub sans dépendre du présent document.

6. Livrables et mode d'exécution

1. Ouvrir le notebook TP1_Systemes_de_recommandation.ipynb ou TP2_Filtrage_collaboratif.ipynb dans Colab.
2. Choisir « Exécution > Tout exécuter ». Le notebook télécharge le jeu Grouplens requis et bascule automatiquement vers un miroir si la source ne répond pas.
3. Conserver la connexion internet le temps du premier téléchargement ; les exécutions suivantes réutilisent /content/data.
4. Les métriques et figures sont écrites dans le dossier artifacts du runtime.

Structure livrée :

```
notebooks/TP1_Systemes_de_recommandation.ipynb
notebooks/TP2_Filtrage_collaboratif.ipynb
src/recommender_core.py
tests/test_recommender_core.py
artifacts/metrics_tp1.json et metrics_tp2.json
report/Compte_rendu_TP1_TP2_Systemes_de_recommandation.pdf
```

7. Références

- Grouplens Research. MovieLens Latest Datasets. <https://grouplens.org/datasets/movielens/latest/>
- Grouplens Research. MovieLens 100K Dataset. <https://grouplens.org/datasets/movielens/100k/>
- Sarwar, B. et al. Item-Based Collaborative Filtering Recommendation Algorithms. WWW, 2001.
- Koren, Y., Bell, R., Volinsky, C. Matrix Factorization Techniques for Recommender Systems. IEEE Computer, 2009.
- Järvelin, K., Kekäläinen, J. Cumulated Gain-Based Evaluation of IR Techniques. ACM TOIS, 2002.